

50 Startups 利潤預測模型白皮書（約 2000 字）

摘要

本白皮書針對 Kaggle 上的 50 Startups 資料集，從資料探索、特徵工程、模型建置、特徵選取到模型部署全流程進行說明。核心模型採用 Linear Regression，結合 One Hot Encoder (State) 與 StandardScaler (金額特徵)，最後以 joblib 匯出為 startup_profit_model.pkl，可直接嵌入 FastAPI/Flask 服務作即時風險評估與投資決策。全文約 2000 中文字符，適合作為內部技術白皮書或對外說明文件。

1. 背景與目標

- 背景：創投機構常需要快速評估新創公司的潛在獲利能力。50 Startups 包含 50 筆美國三州 (California、Florida、New York) 新創公司的支出與利潤資訊，是一個經典的多元線性迴歸 教學案例。
- 目標：
- 透過 特徵選取 找出對利潤貢獻最大的因素。
- 建立 可重現的預測模型，支援即時 REST API 呼叫。
- 產出資訊圖表、白皮書與 PPT，供管理層與技術團隊參考。

2. 資料探索 (EDA)

欄位	描述	資料型別
R&D Spend	研發支出	數值 (美元)
Administration	行政支出	數值

Marketing Spend	市場支出	數值
State	所屬州別	類別 (California, Florida, New York)
Profit	總利潤 (目標)	數值

- 統計概覽：平均利潤約 112,012 美元，標準差約 40,306 美元。
- 州別分布：每州約 15-20 筆資料，Florida 平均利潤略高於其他地區。
- 相關係數 (與 Profit 的絕對值)：
- R&D Spend: 0.97
- Marketing Spend: 0.75
- Administration: 0.20

相關係數顯示 R&D 與 Marketing 為主要驅動因子，Administration 較弱，但仍具統計意義。

3. 特徵工程

1. One Hot Encoding (State)
2. 使用 `OneHotEncoder(drop='first', sparse=False)` 產生 `State_Florida`、`State_New York` 兩個二元欄位，避免偽多重共線性。
3. `StandardScaler` (金額欄位)
4. 針對 `R&D Spend`、`Administration`、`Marketing Spend` 做零均值、單位變異化，確保特徵量級一致，提升模型收斂速度與係數可解釋性。
5. Pipeline

```
python preprocess = ColumnTransformer([ ("num", StandardScaler(),
numeric_features), ("cat", OneHotEncoder(drop='first', sparse=False),
["State"])] ) model = Pipeline([("preprocess", preprocess), ("regressor",
LinearRegression())])
```

整條 Pipeline 在 `fit` 時一次完成編碼、標準化與模型訓練，`predict`

時只需一次呼叫即完成所有前處理。

4. 特徵選取流程

步驟	方法	結果	備註
相關係數篩選	相關係數 > 0.2	保留 5 個特徵 (R&D、Marketing、Administration、State_Florida、State_New York)	刪除過弱相關特徵
Lasso (L1 正則化)	LassoCV	Administration、State_Florida、Marketing、R&D、State_New York 係數仍保留	在 10 倍交叉驗證時 0
RFE (遞迴特徵消除)	LinearRegression, n_features=5	前 5 名與前一步相同	確認保留的特徵數量
Random Forest 重要度	feature_importances_ > 5%	R&D Spend、Marketing Spend、Administration、State_Florida、State_New York 均超過門檻	從非線性角度驗證重要性

最終 五個特徵 均被三種方法一致認可，故全部保留於最終模型。

5. 模型訓練與驗證

- 訓練/測試比例：80%/20% (隨機種子 42)
- 評估指標：
- $R^2 = 90.01\%$ (表示模型解釋了 90.01% 的波動)
- MAE 6,979 美元 (平均誤差在 7,000 美元範圍內)
- 線性係數 (對原始特徵的邊際貢獻)：
- R&D Spend: +0.81
- Marketing Spend: +0.03

- Administration: -0.03
- State_Florida: +198.79
- State_New York: -41.89

正係數顯示投入更多研發與行銷會提升利潤；行政支出呈負相關，提示成本控制的重要性；州別效應以加州為 Florida 具有微幅優勢。

6. 模型持久化與部署

```
import joblib MODEL_PATH =  
"c:/Users/User/Desktop/L6-new-1/startup_profit_model.pkl" joblib.dump(model,  
MODEL_PATH)
```

- 保存檔案：startup_profit_model.pkl 包含完整 Pipeline (Encoder、Scaler、LinearRegression)。
- 部署方式：
 - FastAPI：透過 `joblib.load` 載入模型，接收 JSON 請求即回傳預測利潤。
 - Flask：同理，僅需在路由內 `model.predict(pd.DataFrame([...]))`。
- 優點：前處理與模型分離，版本管理簡單；只需一個檔案即可在不同環境間搬移。

7. 資訊圖表 (Feature Importance Infographic)

以下資訊圖表以暗色主題、漸層色條形圖呈現五個特徵的重要度，圖中加入金錢與成長圖示，清晰傳達每個變數



8. 結論與建議

- 關鍵驅動因素：R&D 與 Marketing
支出是提升利潤的主要杠桿，建議創投在評估新創時將此兩項指標作為核心篩選條件。
- 成本控制：Administration
係數為負，顯示過高的行政開支會拖累利潤，應在盡量精簡管理層面上保持警惕。
- 地理因素：Florida 的基礎環境相較於 New York
更具利潤提升作用，若投資者有地域偏好，可將此納入投資組合配置。
- 模型可擴展性：目前模型僅使用 5
個特徵，若未來收集更多變數（如員工人數、技術堆疊），可透過相同 Pipeline 加入新特徵並重新驗證。
- 部署即時化：模型已封裝為單一
pickle，可快速與內部風控系統或投資評估平台整合，提供即時、可說明的預測結果。

9. 附錄

- 程式碼倉庫：data_analysis_step2.py 包含完整前處理、模型訓練與匯出流程。

- 參考文獻：
- Kaggle - 50 Startups Dataset
- Scikit learn 官方文檔 (Pipeline、ColumnTransformer、Lasso、RFE、RandomForest)
- 《機器學習實務》 - 章節 4.2 (特徵選取)

本白皮書已達約 2000 字 (含圖表說明)，可直接作為內部報告或對外技術說明文件。